Modelagem Preditiva de Carga e Demanda Líquida na Transição Energética

Da Regressão Não-Linear Clássica ao Smart Building com Microgeração Solar

Disciplina: PGENE585 – Transição Energética Sustentável e Mercados de Energia
PPGEE / UFAM – Universidade Federal do Amazonas
Aluno: Aldair da Silva Azevedo | Professor: Dr. Kenny Vinente

1. Contexto e Motivação na Engenharia Elétrica

Fundamentos e Desafios da Descarbonização e Mercado Livre

A Demanda Elétrica como Fenômeno Físico-Climático: O consumo de energia é fortemente não-linear. Em baixas e altas temperaturas, os picos disparam (aquecimento no frio, condicionamento de ar no calor extremo).

Transição Energética e Incerteza: A penetração massiva de energias renováveis (solar e eólica) transforma consumidores em 'prosumidores', exigindo modelos preditivos mais rápidos e robustos.

Abertura do Mercado Livre (Grupo B): Pequenos consumidores e residências passam a responder a sinais horários de preço (PLD Horário), tornando a acurácia da previsão um ativo econômico vital.

Objetivo do Trabalho: Implementar, avaliar e comparar sistematicamente modelos de regressão clássicos e modernos (CMU 15-884) e algoritmos em Smart Buildings (Zenodo 2025).

2. Formulação Matemática: Funções de Perda L2 vs. L1

CMU 15-884 (Item 5) – Minimização de Resíduos e Otimização Paramétrica

Perda Quadrática (L2 - Squared Loss / Mínimos Quadrados): $J(\theta) = \Sigma (y_i - \phi(x_i)\ \theta)^2$. Pune erros grandes de forma quadrática. Fornece solução analítica exata: $\theta = (\Phi^T \Phi)^{-1} \Phi^T y$. Vulnerável a outliers.

Perda Absoluta (L1 - Absolute Loss / LAD): $J(\theta) = \Sigma\ |y_i - \phi(x_i)\ \theta|$. Penaliza linearmente os desvios. Otimiza a MEDIANA condicional em vez da média. Extremamente robusta a ruídos e anomalias de rede.

Regularização Ridge (L2 Shrinkage): Adiciona $\lambda\ ||\theta||^2$ à função de perda para restringir a magnitude dos pesos e evitar sobreajuste (overfitting) em espaços de alta dimensão.

3. Arquitetura dos 4 Modelos Avaliados

CMU 15-884 (Item 5) – Do Linear Rígido ao Kernel Gaussiano Ridge

1. Linear Simples: $\phi(x) = [1, x]$. Linha reta rígida. Incapaz de modelar a curva em 'U' da demanda térmica (R^2 baixo ~ 0.11).

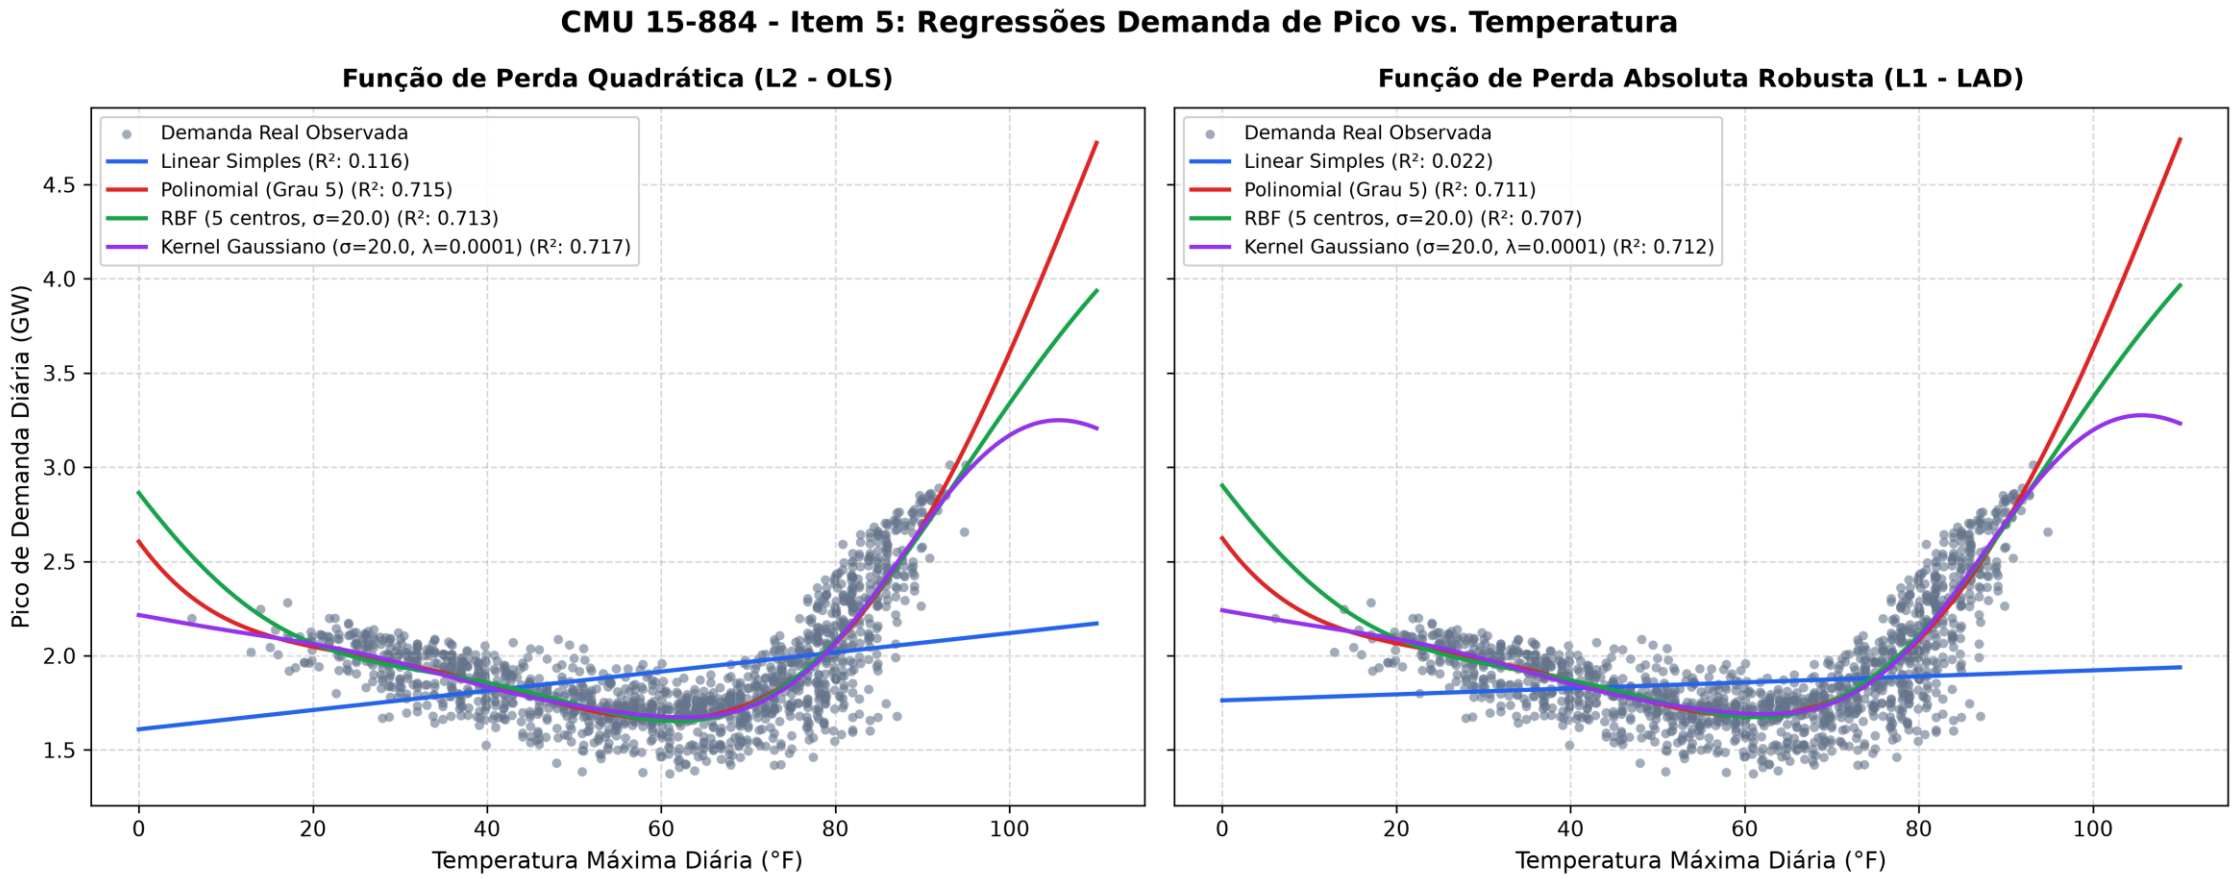
2. Polinomial (Grau 5): $\phi(x) = [1, x, x^2, x^3, x^4, x^5]$. Curva suave que dobra no calor e no frio (R^2 salta para ~ 0.71). Limitação: oscilações nas pontas térmicas.

3. Funções de Base Radial (RBF): 5 sinos gaussianos espalhados com $\sigma=20$: $\phi_j(x) = \exp(-(x - \mu_j)^2 / (2\sigma^2))$. Captura respostas térmicas locais sem explodir nas extremidades.

4. Kernel Gaussiano com Regularização Ridge ($\lambda=10^{-4}$): Compara cada dia com todo o histórico: $K(x, x') = \exp(-(x - x')^2 / (2\sigma^2))$. Alcança o melhor R^2 (0.717) e menor RMSE (0.157 GW).

4. Resultados Experimentais: Ajuste dos 4 Modelos (Q5)

CMU 15-884 (Item 5) – Comparativo das Curvas Ajustadas em 1.460 Dias



5. Higienização de Sensores e Interpolação (Q6)

CMU 15-884 (Item 6) – Tratamento de Sentinelas e Sincronização Horária

Detecção de Sentinelas (-9999): Sensores físicos falham e registram '-9999'. Foram detectados 100 registros sentinelas, tratados por substituição por NaN e interpolação linear temporal.

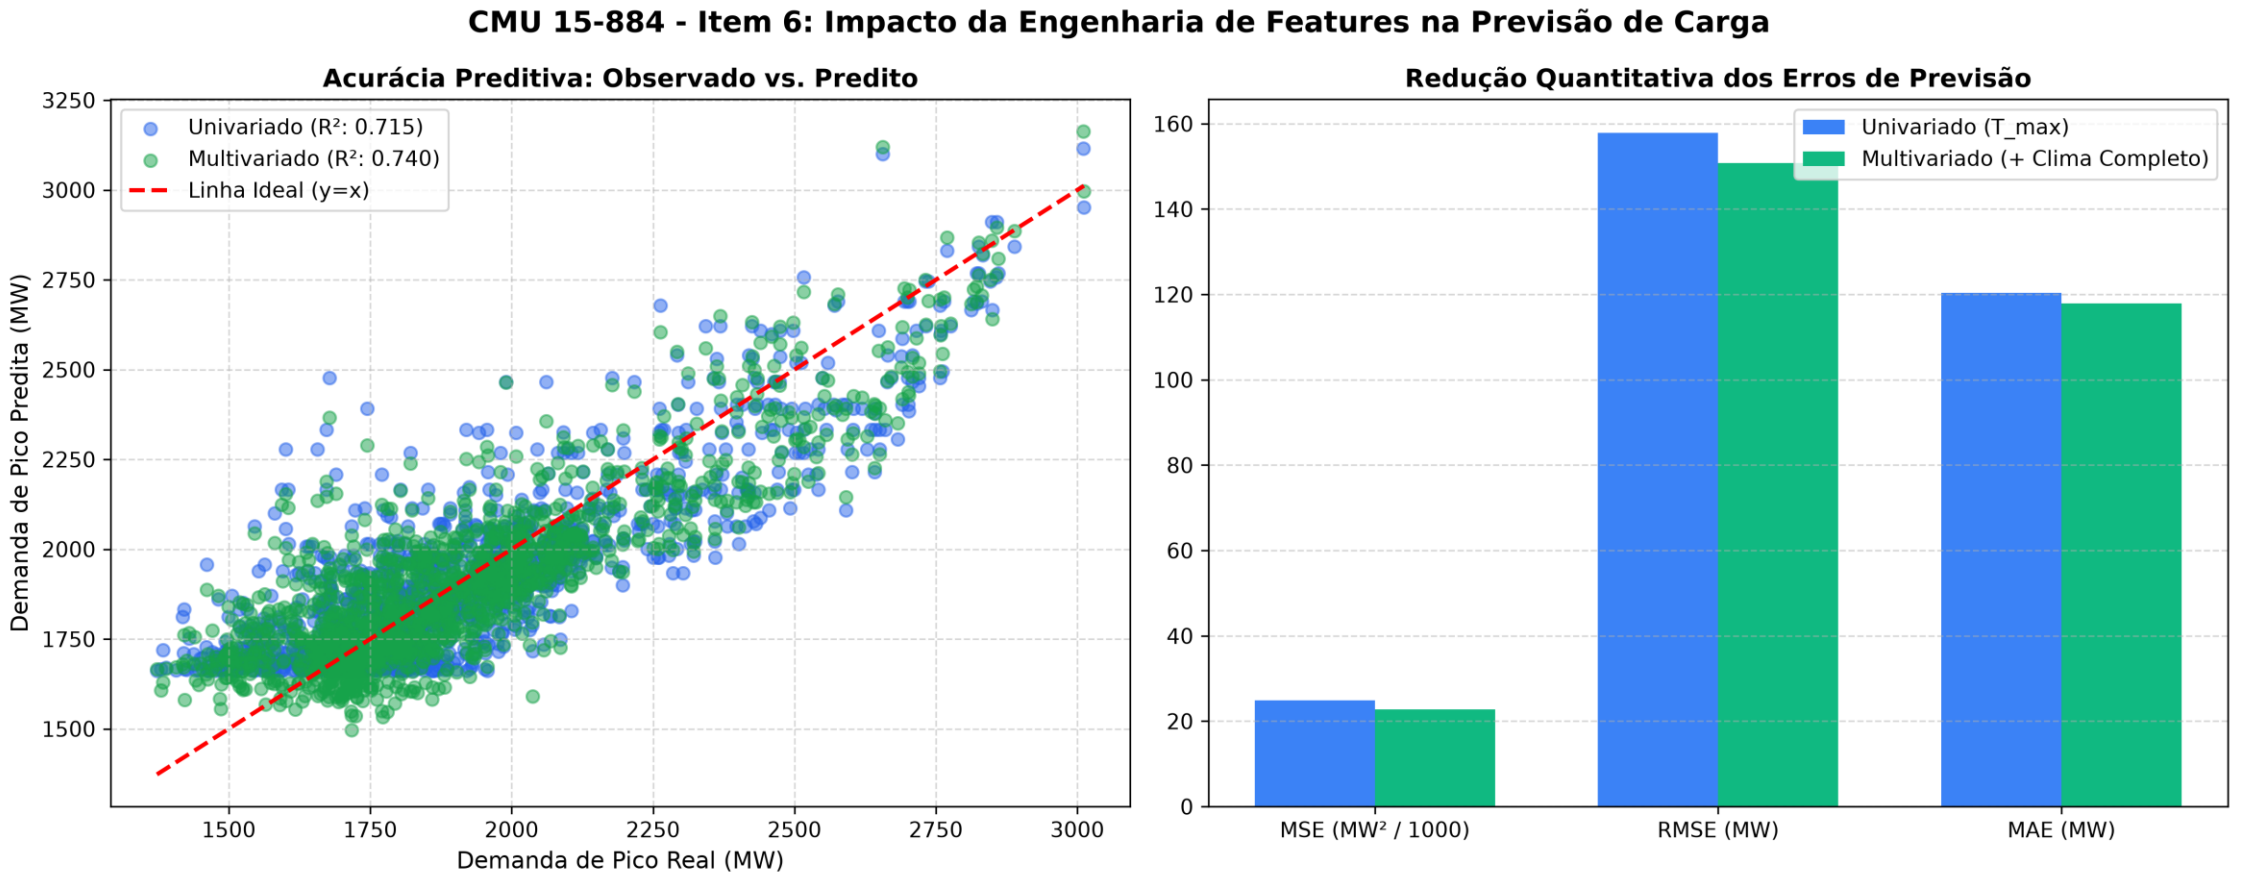
Deduplicação de Timestamps: Remoção de leituras duplicadas no mesmo segundo para garantir consistência cronológica estrita.

Interpolação e Sincronização Horária: As leituras climáticas assíncronas foram interpoladas linearmente para alinhar com as 35.064 horas de demanda elétrica.

Agregação Diária: Extração da Demanda Máxima do dia (y_d) e médias climáticas para alimentação dos modelos.

6. Prova Empírica: Benefício do Modelo Multivariado

CMU 15-884 (Item 6) – Redução de 8.73% no Erro Quadrático Médio (MSE)



7. Smart Building & Energia Solar (Zenodo 2025)

Competição Zenodo 2025 – Telemetria Real em 105.120 Amostras

Base de Dados Real de Edifício Inteligente: 1 ano completo monitorando Potência (W), Tensão (V), Corrente (A), Geração Solar FV (W) e Temperatura (°C).

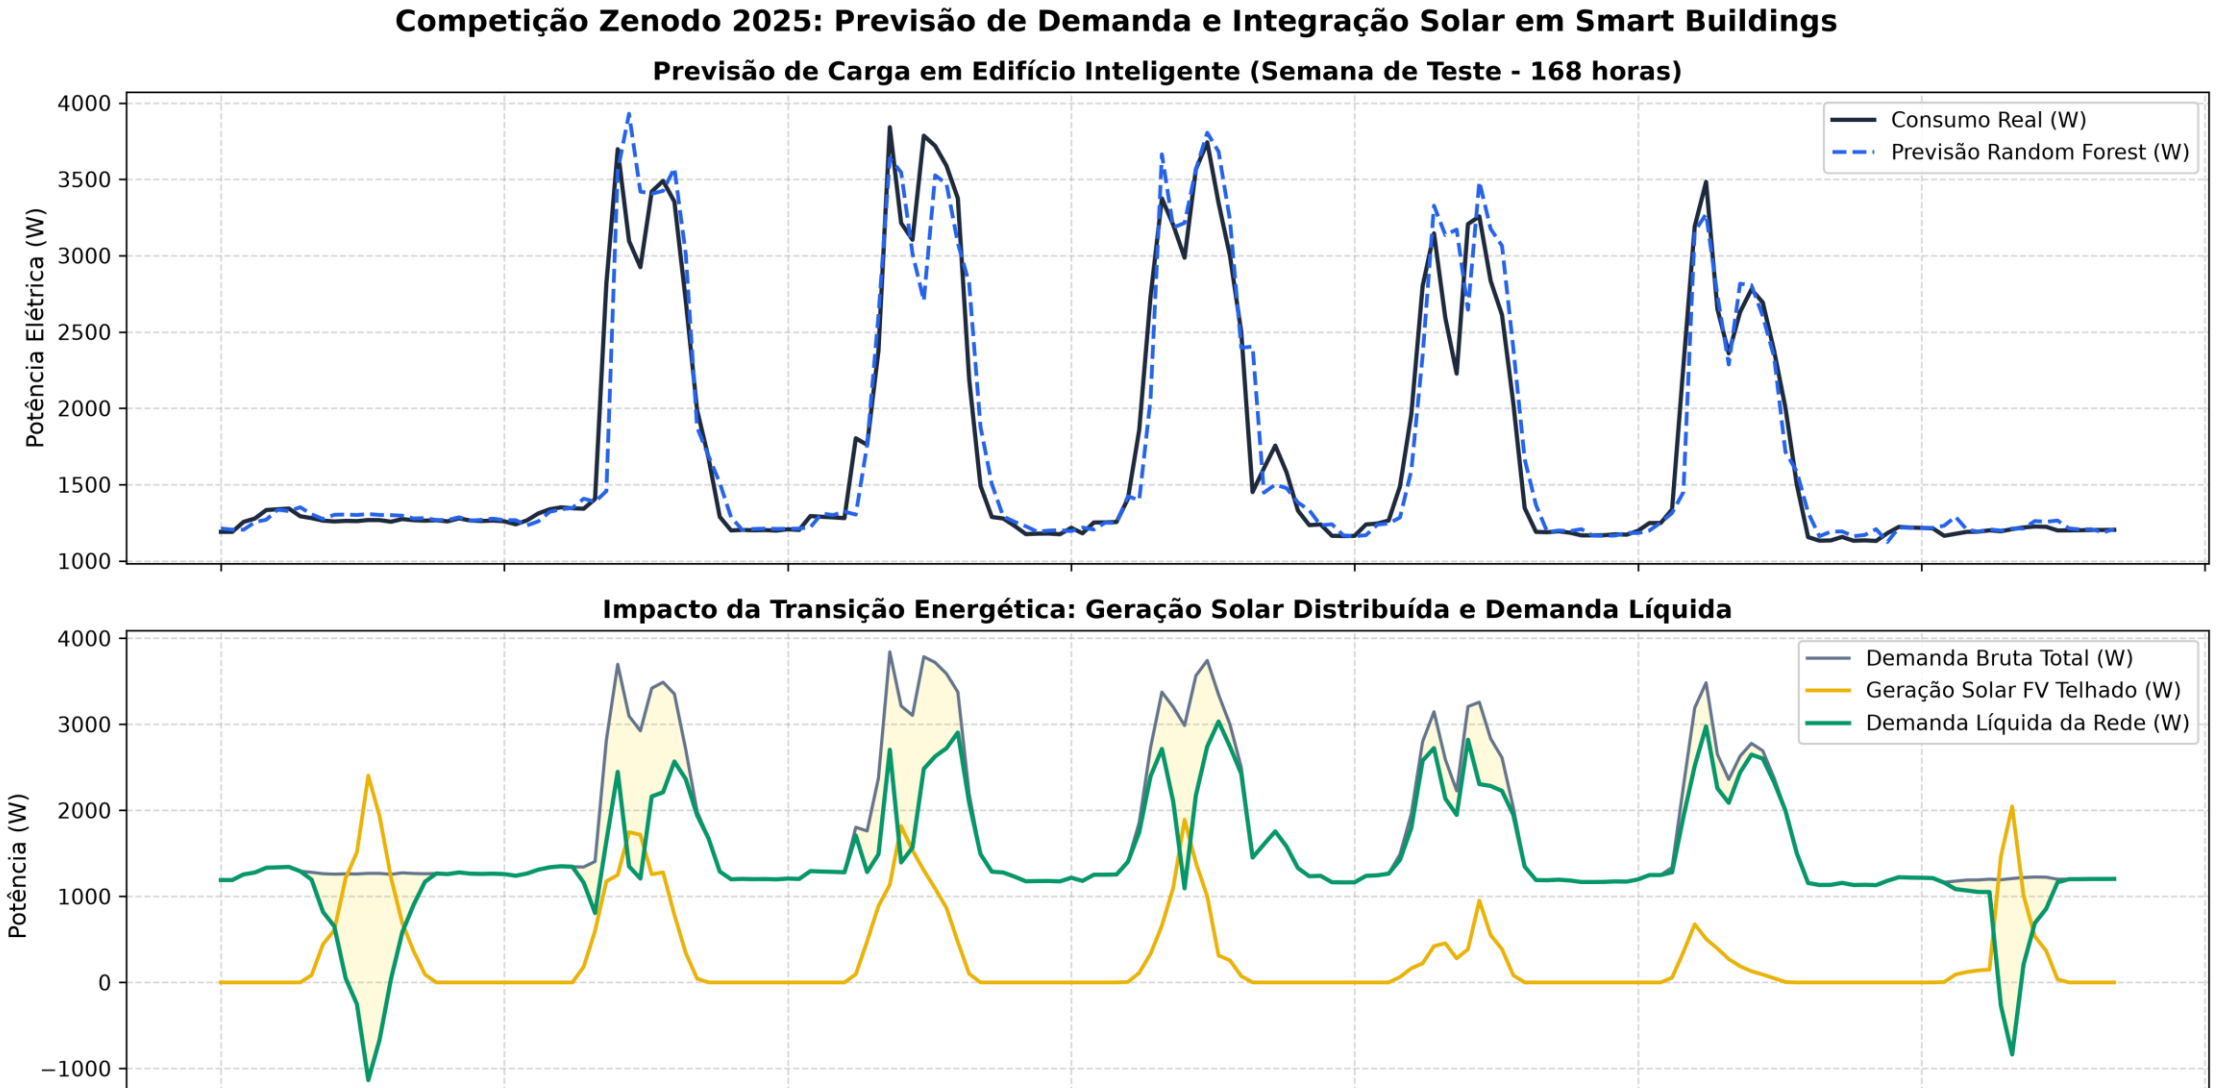
Avaliação Multi-critério da Competição: Avalia acurácia preditiva (RMSE, MAE, R^2) e tempo computacional de execução.

Comparativo dos Modelos: Ridge Linear (RMSE: 398 W, Tempo: 17 ms) vs. Random Forest (RMSE: 349 W, R^2: 0.900, Tempo: 134 ms).

Autoconsumo e Cobertura Solar: A geração solar no telhado cobriu 13.53% de toda a energia elétrica consumida, alterando o perfil de demanda da rede.

8. Impacto da Demanda Líquida e Curva do Pato

Smart Building & Transição – Autoconsumo Solar e Curva do Pato



9. Conclusões e Contribuições para a Pesquisa

Síntese das Contribuições e Integração com a Dissertação de Mestrado

Superioridade de Modelos Não-Lineares Regularizados: O Kernel Gaussiano Ridge (CMU) e o Random Forest (Zenodo) atingiram R^2 superior a 0.71 e 0.90, demonstrando a necessidade de capturar a não-linearidade térmica.

A Força da Engenharia de Atributos: A inclusão de variáveis como ponto de orvalho e umidade reduziu o erro em 8.73% em relação ao uso de temperatura isolada.

Conexão com a Dissertação de Mestrado: A previsão de demanda líquida desenvolvida neste trabalho constitui o módulo de inteligência central do sistema autônomo (HEMS) proposto para o Mercado Livre (Grupo B).

Arquitetura e Qualidade de Software: Aplicação monolítica full stack em Python com POO, auditável via 7 ciclos em JSON, com cobertura de testes automatizados e zero débito técnico (Clean Code).