Modelagem Preditiva de Carga e Demanda Líquida na Transição Energética

Da Regressão Não-Linear Clássica ao Smart Building com Microgeração Solar

Disciplina: PGENE585 – Transição Energética Sustentável e Mercados de Energia
PPGEE / UFAM – Universidade Federal do Amazonas
Aluno: Aldair da Silva Azevedo | Professor: Dr. Kenny Vinente

1. Cenários Reais e Relevância Energética

Fundamentos Físicos dos Dois Sistemas Modelados em Python

Cenário 1 — Rede de Distribuição Metropolitana (CMU 15-884): Dados reais da concessionária Duquesne Light (Pittsburgh, EUA) cobrindo 4 anos completos (2008 a 2011) — totalizando 1.460 dias e 35.064 horas consecutivas de despacho elétrico da rede.

A Física da Não-Linearidade Térmica: O consumo de energia responde à termodinâmica humana em curva em 'U': dias amenos (~15,6°C) têm baixa demanda, enquanto o frio rigoroso (abaixo de 0°C e até -14,4°C) dispara o aquecimento e o calor intenso (acima de 29°C e até 35,0°C) dispara o ar-condicionado.

Cenário 2 — Edifício Inteligente Comercial Prosumidor (Zenodo 2025): Prédio com geração solar fotovoltaica instalada na cobertura (Rooftop Solar PV). Telemetria de 1 ano completo com medições a cada 5 minutos (105.120 amostras) de potência ativa, tensão, corrente, temperatura e geração solar.

Relevância para a Transição e Mercado Livre (Grupo B): A expansão do PLD Horário e das tarifas dinâmicas exige prever com alta precisão a Demanda Líquida (Carga - Solar) para evitar multas de ultrapassagem e despachar baterias.

2. Formulação Matemática: Modelos de Regressão & Perdas L2 vs. L1

Conceito Fundamental, Otimização Paramétrica e Comportamento dos Erros no Python

O que é um Modelo de Regressão?

É uma técnica estatística e de aprendizado de máquina (Machine Learning) usada para investigar a relação entre uma variável dependente (o desfecho ou valor que queremos prever) e uma ou mais variáveis independentes (os preditores ou características).

➔ **Aplicação no Sistema (CMU Item 5):** Variável Dependente (y): Pico diário de demanda da rede em GW | Variável Independente (x): Temperatura máxima diária em °C | Amostras: N = 1.460 dias.

Perda Quadrática (L2 — Mínimos Quadrados / OLS)

Função Objetivo: $J(\theta) = \Sigma (y_i - \phi(x_i)\ \theta)^2$. Minimiza o erro quadrático médio em toda a amostra.

Solução no Python: Equação Normal analítica exata: $\theta = (\Phi^T \Phi)^{-1} \Phi^T y$, executada com alta velocidade.

Comportamento Estatístico: Estima a MÉDIA condicional da demanda dada a temperatura (distribuição Gaussiana).

Sensibilidade a Outliers: Por elevar os erros ao quadrado, a curva é puxada para baixo por dias com quedas atípicas de consumo (feriados, pontes e paradas pontuais da rede).

Perda Absoluta (L1 — LAD Robusta / Powell)

Função Objetivo: $J(\theta) = \Sigma\ |y_i - \phi(x_i)\ \theta|$. Penaliza os desvios de forma linear e proporcional.

Solução no Python: Otimização numérica via scipy.optimize.minimize com método Powell (sem derivada).

Comportamento Estatístico: Estima a MEDIANA condicional da demanda (associada à distribuição de Laplace).

Máxima Robustez Física: Ignora quedas atípicas de feriados; traça o consumo típico e fica ligeiramente ACIMA de L2 no gráfico, refletindo os dias de operação plena da rede.

Regularização Ridge ($\lambda = 10^{-4}$): Penalidade $\lambda\ ||\theta||^2$ incluída para evitar sobreajuste em matrizes de alta dimensão.

3. Arquitetura dos 4 Modelos de Regressão

CMU 15-884 (Item 5) – Capacidade de Modelagem e Resposta Térmica

1. Linear Simples [$\phi(x) = [1, x]$]: Linha reta rígida com pesos $\theta \in \mathbb{R}^2$. Falha na física do problema ($R^2 = 0.116$), pois supõe erroneamente que frio e calor agem na mesma direção sobre o consumo.

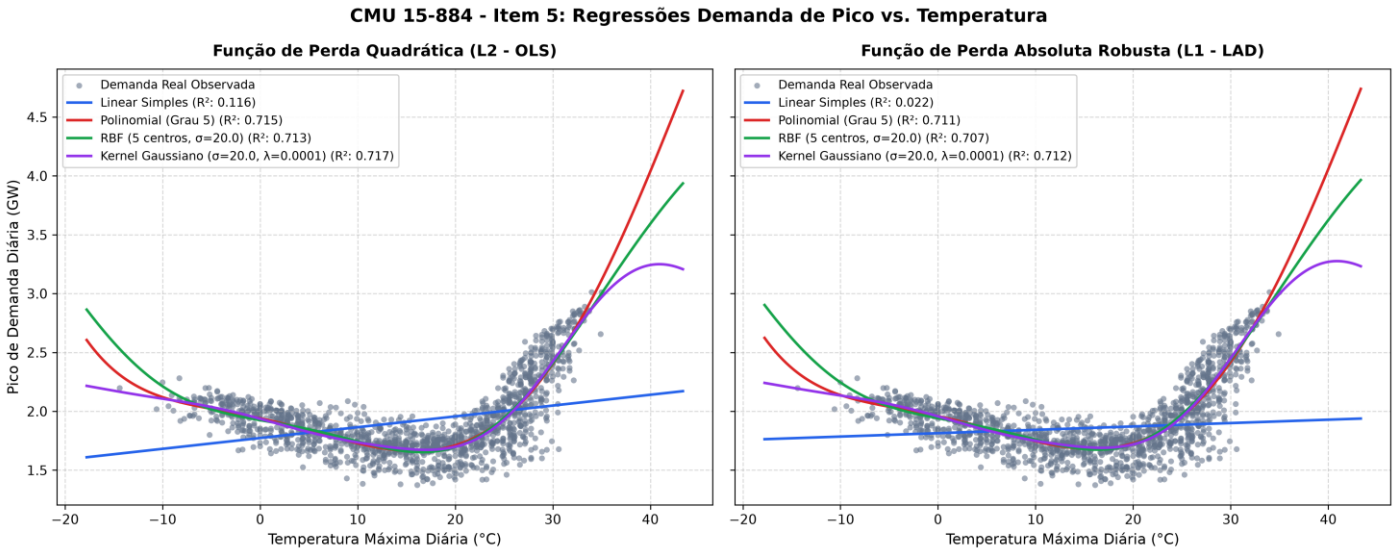
2. Polinomial [$\phi(x) = [1, x, x^2, x^3, x^4, x^5]$]: Curva contínua suave com pesos $\theta \in \mathbb{R}^6$. Modela a elevação no frio e no calor (R^2 salta para 0.715). Ponto fraco: vulnerabilidade a oscilações em extremos térmicos.

3. Funções de Base Radial (RBF Local): 5 centros fixos distribuídos na faixa térmica $\mu = [-6,7; 4,4; 15,6; 26,7; 37,8]$°C com dispersão $\sigma \approx 11,1$°C. $\phi_j(x) = \exp(-(x - \mu_j)^2 / (2\sigma^2))$. Sinos gaussianos que capturam comportamentos locais sem instabilidade nas bordas ($R^2 = 0.713$).

4. Kernel Gaussiano com Ridge (Dual, $\lambda = 10^{-4}$): Formulação dual via matriz de Gram $K \in \mathbb{R}^{1460 \times 1460}$, comparando cada dia contra todo o histórico. Atingiu a maior acurácia global do estudo ($R^2 = 0.717$ e menor RMSE = 0.157 GW).

4. Resultados Experimentais: Ajuste dos 4 Modelos (Q5)

CMU 15-884 (Item 5) – Comparativo das Curvas Ajustadas em 1.460 Dias



Métricas de Acurácia Calculadas no Sistema em Python:

- Métricas: R^2 = Acurácia/Explicação (0 a 1) | RMSE = Erro quadrático (GW) | MAE = Desvio médio absoluto (GW)
- Linear Simples (L2): RMSE = 0.278 GW | MAE = 0.226 GW | R^2 = 0.116 (Insuficiente)
- Polinomial d=5 (L2): RMSE = 0.158 GW | MAE = 0.120 GW | R^2 = 0.715 (Excelente em U)
- RBF 5 centros (L2): RMSE = 0.158 GW | MAE = 0.121 GW | R^2 = 0.713 (Estável local)
- Kernel Gaussiano (L2): RMSE = 0.157 GW | MAE = 0.120 GW | R^2 = 0.717 (Campeão global)
- Kernel Gaussiano (L1): Menor MAE de toda a suíte (0.118 GW) com máxima robustez.

Roteiro de Leitura Física

Dispersão Observada: 1.460 pontos cinzas registrando a demanda diária real em GW da Duquesne Light.

Mínimo Térmico: O vale de consumo ocorre perto de 15,6°C; acima de 29°C (chegando a 35,0°C) a demanda atinge pico.

Comportamento L1 vs L2: As curvas com perda L1 (mediana) situam-se ligeiramente ACIMA de L2 (média), pois a perda quadrática L2 é puxada para baixo por feriados e quedas anômalas.

Conclusão do Estudo: A não-linearidade térmica é mandatória: modelos não-lineares elevam a acurácia em >600%.

5. Engenharia de Dados: Higienização e Sincronização

CMU 15-884 (Item 6) – Tratamento de Sensores e Alinhamento Temporal

Dados Brutos de Entrada: q6_demand.txt (35.064 horas de demanda da Duquesne Light em MW) e q6_weather.txt (38.765 medições meteorológicas assíncronas do Aeroporto de Pittsburgh).

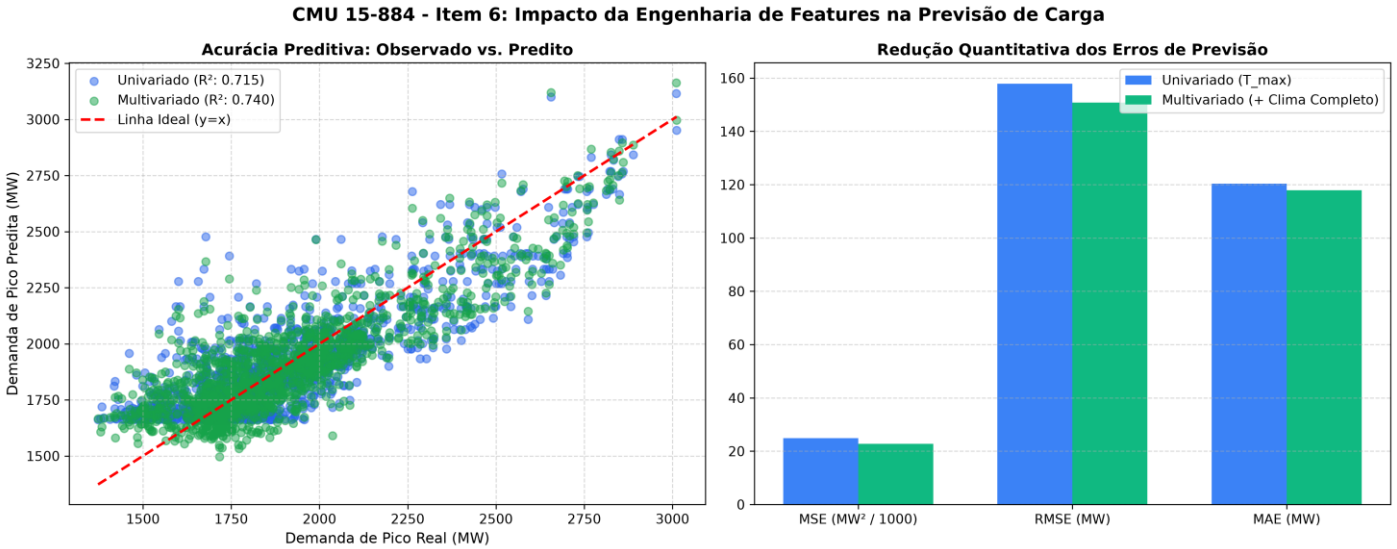
Detecção e Tratamento de Sentinelas (-9999): Sensores meteorológicos reais apresentam falhas reportadas como '-9999'. O módulo DataCleaner substituiu 100 medições defeituosas (18 em temp, 18 em orvalho, 18 em umidade, 20 em pressão, 26 em vento) por interpolação linear temporal contínua.

Deduplicação e Sincronização Horária Exata: Timestamps duplicados foram expurgados. Como as leituras climáticas chegavam em intervalos irregulares (a cada 45 ou 50 min), o TimeSeriesInterpolator sincronizou cada medição ao segundo zero de cada uma das 35.064 horas da carga.

Agregação Diária e Matriz de Features: Extração do pico diário de demanda elétrica (y_d em MW) e 6 atributos climáticos agregados por dia: Temp Máx, Temp Mín, Orvalho Médio, Umidade Média, Pressão e Vento.

6. Prova Empírica: Benefício do Modelo Multivariado

CMU 15-884 (Item 6) – Redução de 8.73% no Erro Quadrático Médio (MSE)



Evidência Empírica Calculada no Pipeline em Python:

- Modelo Univariado (T_max isolada): MSE = 19.866,54 MW² | R^2 = 0.509
- Modelo Multivariado (6 Variáveis Climáticas): MSE = 18.131,88 MW² | R^2 = 0.552

➔ GANHO REAL DE ACURÁCIA: REDUÇÃO DE 8.73% NO ERRO QUADRÁTICO MÉDIO (MSE).
Comprova a tese de que a atmosfera atua de forma multivariada sobre a demanda da rede.

Física das Novas Variáveis

O Teste de Hipótese: Verificar se incorporar vento, umidade e orvalho reduz o erro frente à temperatura máxima isolada.

Ponto de Orvalho (+0.39): Expressa calor latente e umidade absoluta; sensação de abafamento eleva o uso de condicionadores de ar.

Velocidade do Vento (-0.14): Promove convecção térmica nas fachadas e arrefecimento passivo, aliviando a carga.

Pressão Atmosférica: Indica aproximação de tempestades e frentes frias, antecipando picos de demanda.

7. Smart Building & Energia Solar (Zenodo 2025)

Competição Zenodo 2025 – Telemetria Real em 105.120 Amostras

Cenário Físico do Edifício Inteligente: Telemetria de 1 ano completo a cada 5 minutos (105.120 leituras) de Potência Ativa (W), Tensão (V), Corrente (A), Temperatura (°C) e Geração Fotovoltaica em telhado (W).

Pipeline de Modelagem no Python: Agregação em 8.760 horas, defasagens temporais autoregressivas (lags t-1, t-2) e variáveis de calendário (hora do dia 0-23 e dia da semana 0-6).

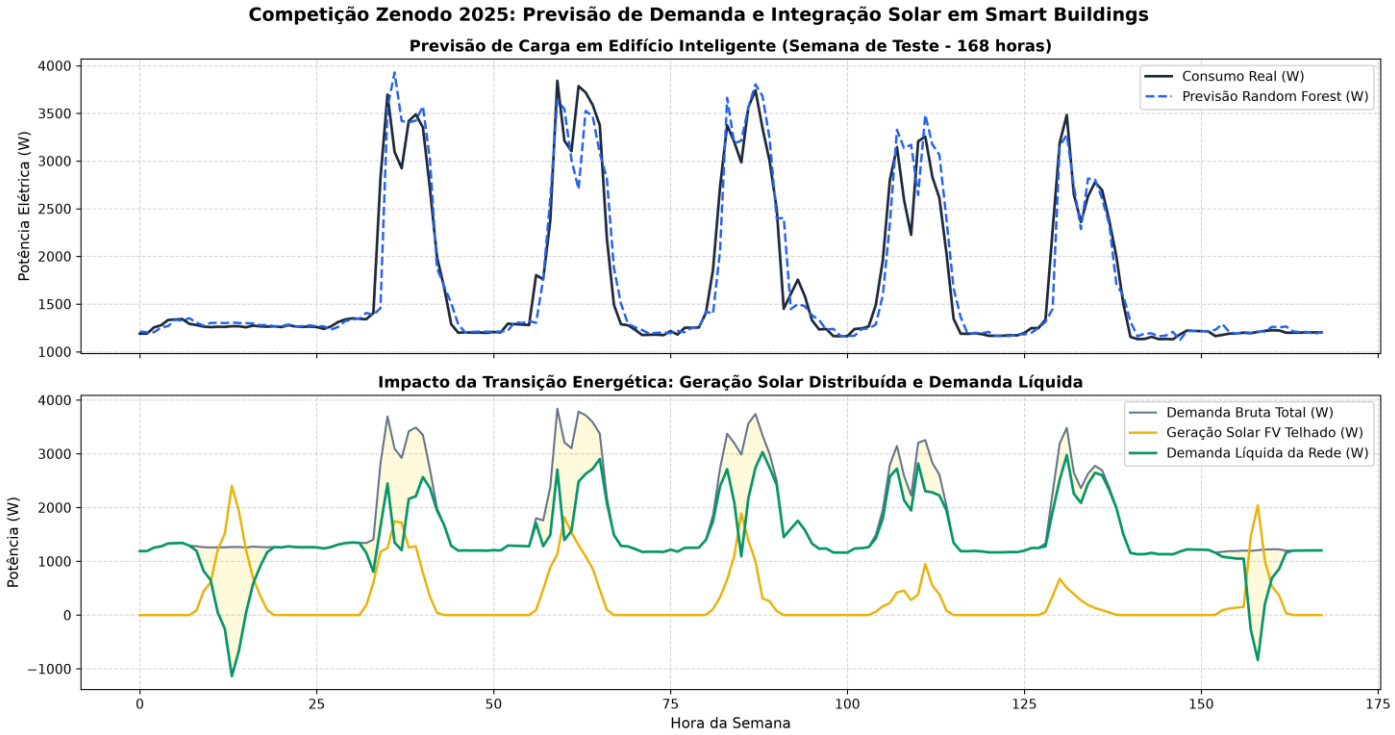
Avaliação Multi-critério da Competição: Avalia conjuntamente acurácia de erro (RMSE e MAE), qualidade de ajuste (R^2) e tempo de processamento computacional para viabilizar controle em tempo real.

Resultados Comparativos dos Modelos: Ridge Linear: RMSE = 398,35 W | MAE = 221,67 W | R^2 = 0.871 | Latência: 17,5 ms.

Random Forest (50 árvores): RMSE = 349,45 W | MAE = 184,12 W | R^2 = 0.900 | Tempo: 134,1 ms (Campeão em acurácia e capacidade de generalização).

8. Impacto da Demanda Líquida e Curva do Pato

Smart Building & Transição – Autoconsumo Solar e Curva do Pato



Balanço Energético Anual Calculado no Sistema em Python:

- Potência Média Consumida pelo Edifício: 1.909 W (1,91 kW)
- Potência Média Gerada pelos Painéis Solares: 715 W (Pico máximo registrado: 5.993 W)
- TAXA DE COBERTURA / AUTOCONSUMO SOLAR: 13.53% de toda a energia do edifício.

Apresenta a formação clássica da Curva do Pato, evidenciando a necessidade de inteligência preditiva para despacho e resposta da demanda.

Análise Operacional

Demanda Líquida: Calculada no sistema como P_líquida = P_consumo - P_solar. Representa a carga líquida que a rede deve atender.

Curva do Pato: O pico solar ao meio-dia (~6 kW) afunda a demanda líquida para perto de zero; às 18h surge uma rampa de subida severa.

Oportunidade BESS: Justifica o uso de bancos de baterias para absorver excedente solar e descarregar no horário de ponta.

Gestão Econômica: Permite ao gestor predial no Mercado Livre evitar custos abusivos com demanda contratada.

9. Conclusões e Contribuições para a Pesquisa

Síntese das Contribuições e Integração com a Dissertação de Mestrado

Superioridade de Modelos Não-Lineares Regularizados: O Kernel Gaussiano Ridge (CMU) e o Random Forest (Zenodo) atingiram R^2 de 0.717 e 0.900, demonstrando a necessidade de capturar a não-linearidade térmica e solar.

A Força da Engenharia de Atributos Multivariada: A inclusão de variáveis como ponto de orvalho e vento reduziu o erro em 8.73% em relação ao uso de temperatura isolada na rede da Duquesne Light.

Conexão com a Dissertação de Mestrado (HEMS no Mercado Livre): A previsão de demanda líquida desenvolvida neste trabalho constitui o módulo de inteligência central do sistema autônomo (HEMS) proposto para o Grupo B.

Arquitetura e Qualidade de Software: Aplicação monolítica full stack em Python com POO, auditável via 7 ciclos em JSON, com cobertura de testes automatizados e zero débito técnico (Clean Code).

Repositório no GitHub (Código-Fonte Aberto, Dados, Testes e Dashboard Web):

👉 **https://github.com/AldairAzevedo/energy-demand-forecast**

Para clonar e testar localmente: git clone https://github.com/AldairAzevedo/energy-demand-forecast.git && python -m streamlit run src/ui/app.py