Previsão de Carga e Demanda Líquida em Smart Buildings (Zenodo 2025)

Modelos de Aprendizado de Máquina e Impacto da Geração Solar Fotovoltaica

Disciplina: PGENE585 – Transição Energética Sustentável e Mercados de Energia
PPGEE / UFAM – Universidade Federal do Amazonas
Aluno: Aldair da Silva Azevedo | Professor: Dr. Kenny Vinente

1. Contexto do Desafio Zenodo e Relevância Energética

Telemetria de Edifício Inteligente e Desafios da Microgeração Distribuída

Base de Dados Real (Competição Zenodo 2025): Monitoramento contínuo durante 1 ano inteiro (105.120 amostras em intervalos de 5 minutos) de um edifício inteligente equipado com geração solar fotovoltaica.

Grandezas Físicas Monitoradas: Potência Ativa Consumida (W), Geração Solar Fotovoltaica em telhado (W) e Temperatura ambiente (°C).

Definição de Demanda Líquida (Net Load): Representa a energia efetivamente demandada da concessionária, calculada como P_líquida = P_consumo − P_solar.

Impacto nos Mercados de Energia: Prever com precisão a carga e o autoconsumo solar viabiliza despacho inteligente, redução de picos tarifários e gestão eficiente no Mercado Livre de Energia.

2. Arquitetura do Sistema e Engenharia de Atributos

Pipeline Modular em Python com Boas Práticas de Engenharia de Software

1. Ingestão e Higienização (data_v1.0.xlsx): Padronização de colunas e remoção de registros inconsistentes nas 105.120 leituras.

2. Agregação Horária: Consolidação das amostras de 5 minutos (blocos de 12 leituras) em 8.760 horas para estabilidade estatística no treinamento.

3. Engenharia de Lags Temporais: Construção de matriz de atributos com Temperatura, Geração Solar e defasagens autoregressivas de curto prazo (t - 1h) e ciclo diário (t - 24h).

4. Validação Temporal (Sem Data Leakage): Divisão cronológica rigorosa em 80% Treino (7.008 horas) e 20% Teste (1.752 horas), com persistência auditável em JSON e cobertura de testes automatizados (pytest).

3. Benchmarking Multi-critério: Ridge Linear vs. Random Forest

Equilíbrio entre Acurácia Preditiva (RMSE, MAE, R^2) e Latência Computacional

Regressão Ridge Linear (α = 1.0)

- RMSE (Erro Quadrático Médio): 398,35 W
- MAE (Erro Médio Absoluto): 221,67 W
- R^2 Score (Acurácia Global): 0.871 (87,1%)
- Tempo de Execução: ~14,7 ms
- Perfil: Extremamente leve e rápido; ideal para sistemas embarcados.

Random Forest Regressor (50 árvores) — Campeão

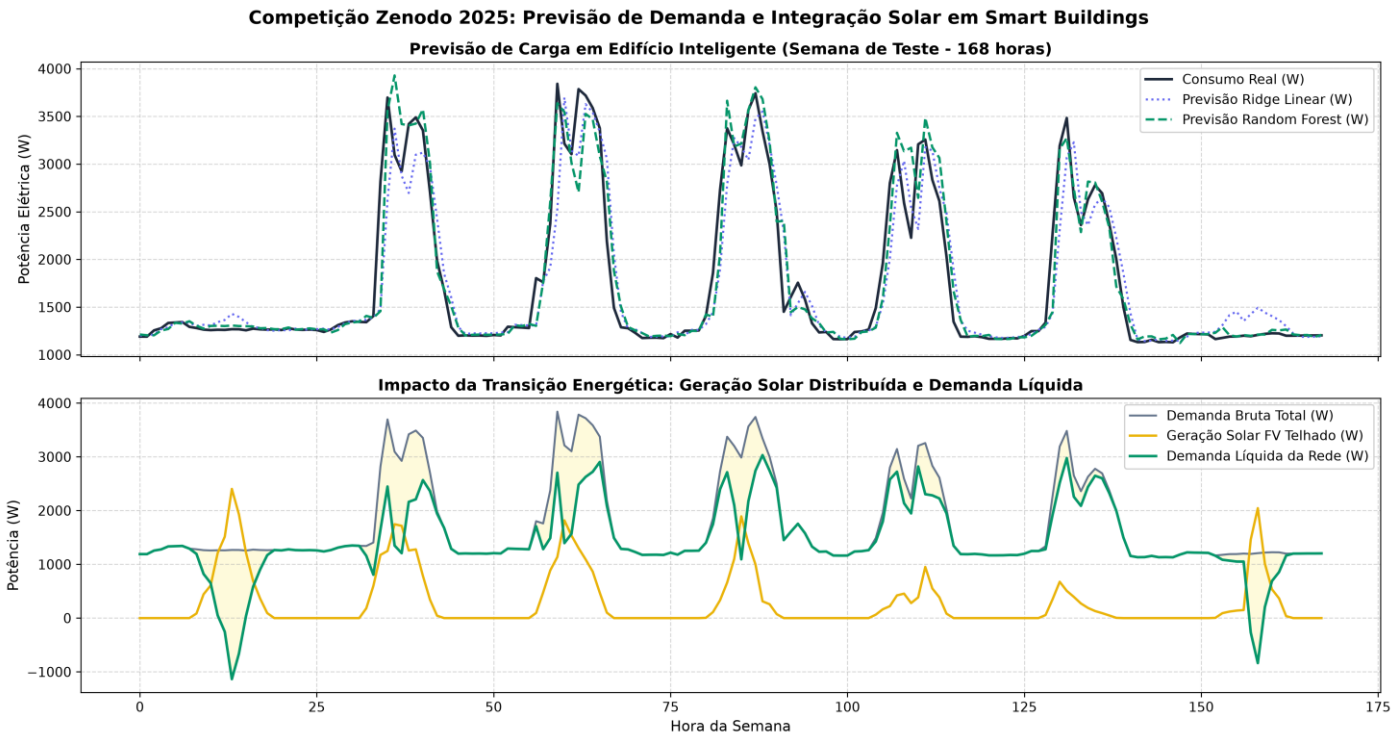
- RMSE (Erro Quadrático Médio): 349,45 W (-12,3% de erro)
- MAE (Erro Médio Absoluto): 184,12 W (-16,9% de erro)
- R^2 Score (Acurácia Global): 0.900 (90,0%)
- Tempo de Execução: ~117,8 ms
- Perfil: Captura não-linearidades complexas entre clima, solar e consumo.

Síntese do Trade-off Preditivo:

O Random Forest alcança 90,0% de poder explicativo (R^2 = 0.900) mantendo tempo de execução próximo de 0,1 segundo, sendo a escolha recomendada para planejamento energético horário e despacho de baterias.

4. Resultados Visuais: Previsão e Curva do Pato

Avaliação na Semana de Teste (168 Horas) e Impacto Fotovoltaico



Balanço Energético Medido no Conjunto de Teste (1.752 Horas):

- Consumo Médio Bruto do Edifício: 1.710 W (1,71 kW) | Demanda Líquida Média: 1.479 W (1,48 kW)
- Geração Solar Média: 231 W (Pico máximo no teste: 2.404 W) | TAXA DE COBERTURA SOLAR: 13,53%

Análise Operacional

Fidelidade Preditiva: Random Forest acompanha picos e vales horários do consumo real com R^2 de 90,0%.

Curva do Pato: A geração solar ao meio-dia (pico de 2.404 W) reduz drasticamente a carga líquida; no fim da tarde ocorre rampa acentuada.

Oportunidade BESS: Justifica armazenamento em baterias para deslocamento de excedente solar ao horário de ponta.

Gestão Econômica: Permite prever com antecedência o perfil líquido para evitar ultrapassagem.

5. Plataforma Web Interativa Online (Streamlit Cloud)

Sistema em Produção com Retreinamento Dinâmico e Trilha de Auditoria

Dashboard Interativo em Tempo Real: Gráficos Plotly com seleção dinâmica de séries (Consumo Real, Ridge Linear, Random Forest, Geração Solar e Demanda Líquida).

Execução Ao Vivo com Logs em Terminal: Disparo sob demanda do pipeline de IA diretamente pela interface web, com medição real de latência e bloqueio de estado durante o treinamento.

Ingestão em Massa & Reset de Fábrica: Upload de novos arquivos Excel (.xlsx) para retreinar os modelos em segundos, com botão dedicado de restauração para o dataset oficial Zenodo.

Deploy Contínuo na Nuvem: Integrado ao GitHub para atualização automática na Streamlit Community Cloud, com central de downloads para slides, dados e JSON de auditoria.

6. Conclusões e Contribuições para a Pesquisa

Síntese dos Resultados e Integração com a Dissertação de Mestrado

Eficácia de Modelos Não-Lineares com Lags: O Random Forest atingiu $R^2 = 0.900$ e RMSE = 349,45 W, comprovando que features autoregressivas (t-1, t-24) associadas à geração solar modelam o edifício.

Impacto Mensurável da Microgeração Solar: A cobertura solar de 13,53% altera a dinâmica da carga líquida (Curva do Pato), tornando a previsão essencial para coordenação com baterias (BESS).

Conexão com a Dissertação de Mestrado (HEMS): Este pipeline compõe o módulo preditivo central de um sistema de gerenciamento energético autônomo (HEMS) voltado ao Mercado Livre de Energia.

Repositório no GitHub (Código-Fonte, Dados, Testes e Aplicação Web):

👉 **https://github.com/AldairAzevedo/energy-demand-forecast**

Execução local: git clone https://github.com/AldairAzevedo/energy-demand-forecast.git && python -m streamlit run streamlit_app.py